

# 一. 浮点数表示与方程求解. Ch 0.1

1	8	23
S	Exponent	Fraction

符号 exp -127 去掉开头的1剩下的部分

例: 1 10000000 10010...0 负数 exp -127 = 1

11.001 = 3.125

2. 截断误差: Truncation Error 舍入误差: Roundoff Error (four-digit rounding arithmetic 四位舍入)

绝对误差:  $|P - P^*|$

相对误差:  $|P - P^*| / |P|$  (P为精确值)

绝对误差限 =  $\frac{1}{2} \times 10^{n-m}$  为原数 m为有效数字位

3. 收敛速度:  $|\beta_n|_{n \rightarrow \infty}$  收敛于0, (通常  $\beta_n = \frac{1}{n^r}$ ),  $|a_n|_{n \rightarrow \infty}$  收敛于a, 若  $|a_n - a| \leq K|\beta_n|$ , 则收敛速度为  $O(\beta_n)$

例:  $\lim_{h \rightarrow 0} \frac{\sinh h}{h} = 1$ ,  $|\frac{\sinh h}{h} - 1| = |\frac{h - \frac{h^3}{6} - h + O(h^2)}{h}| = |-\frac{h^2}{6} + O(h^2)| \leq O(h^2)$

例: 真值  $X^* = 3.141592$ ,  $X = 3.141$ , 有效数字位数:  $|X^* - X| < 0.005 = 0.5 \times 10^{-3}$ , 1为n, 3为m,  $\therefore m=3$

例:  $X^* = 1.333$ , 前三位为有效数字

绝对误差限  $\varepsilon = \frac{1}{2} \times 0.01 = 0.5 \times 10^{-2}$

## 二. 一元方程求解. Ch 2

1. 二分法 误差:  $|P_n - P| \leq \frac{b-a}{2^n}$

例: 误差不超过  $10^{-5}$ , 区间 (2, 4), 二分次数最少为多少?  
 $\frac{1}{2^{k+1}}(b-a) \leq 10^{-5} \therefore k = \lceil \lg 6.6 \rceil = 11$

2. 不动点法 (简单迭代法)

$X = \varphi(X)$  不动点方法  $X^* = \varphi(X^*)$  不动点

$\varphi(x) \in [a, b]$  } 不动点唯一且收敛. 误差:  $\begin{cases} \frac{L}{1-L} |X_k - X_{k+1}| \text{ 事后} \\ \frac{L^k}{1-L} |X_1 - X_0| \text{ 事先} \end{cases}$

不动点收敛速度排序: 首先保证  $\varphi'(x) < 1$ .

将真值分别代入原式、1阶导... 求出收敛阶.

高阶收敛:  $\varphi(X_k) = 0, \varphi'(X_k) = 0 \dots \varphi^{(m)}(X_k) \neq 0$ , 则为m阶收敛.

3. 牛顿迭代法 (切线法)

$$X_{k+1} = X_k - \frac{f(X_k)}{f'(X_k)}$$

若  $f(x)$  有2阶导则至少平方收敛.

$\forall X_0, f(X_0) \cdot f'(X_0) > 0$ , 则收敛.

割线法 (弦截法): 将  $f'(X_k)$  换为  $\frac{f(X_k) - f(X_{k-1})}{X_k - X_{k-1}}$

牛顿下山法:  $\begin{cases} X_{k+1}^* = X_k - \frac{f(X_k)}{f'(X_k)} \\ X_{k+1} = \lambda X_{k+1}^* + (1-\lambda)X_k \end{cases}$   $\lambda$ : 下山因子使  $|f(X_{k+1})| < |f(X_k)|$  下山成功

例: 求  $\sqrt[3]{6}$  的迭代公式.

令  $x = \sqrt[3]{6}$  则  $f(x) = x^3 - 6 = 0, x \in [1, 2]$

$f'(x) = 3x^2 > 0$ , 在  $[1, 2]$  有解.

$$X_{k+1} = X_k - \frac{X_k^3 - 6}{3X_k^2}$$

取  $X_0 = \frac{1}{2}$ ,  $f(X_0) \cdot f'(X_0) = 2.12 > 0$ , 收敛

收敛速度排序

4. 秦九韶算法 (Horner 算法)

$$\begin{cases} T_n = a_n \\ T_k = X T_{k+1} + a_k \\ P(X) = T_0 \end{cases}$$

eg.  $P_4(X) = 3X^4 + 4X^3 - 2X^2 + 3X + 1$

$$T_4 = 3$$

$$T_1 = 2 \cdot T_4 + 3 = 39$$

$$T_3 = 2 \cdot T_4 + 4 = 10$$

$$T_0 = 2 \cdot T_1 + 1 = 79$$

$$T_2 = 2 \cdot T_3 - 2 = 18$$

5. 迭代法的误差分析.

$$\lim_{n \rightarrow \infty} \frac{|P_{n+1} - P|}{|P_n - P|^a} = \lambda \quad a \text{ 为收敛阶数.}$$

6. 快速迭代

$$\Delta P_n = P_{n+1} - P_n \Rightarrow \Delta^k P_n = \Delta(\Delta^{k-1} P_n), k \geq 2.$$

## 三. 矩阵求解初步. Ch 6

1. 高斯消去法: 正常迭代消元得到上三角矩阵.

主元绝对值尽可能大. 即:

$$\begin{matrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{matrix} \quad a_{11} \text{ 最大,}$$

$$\begin{matrix} a_{11} & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 0 & a_{32} & a_{33} \end{matrix} \quad a_{22} \text{ 最大 (在这一列中)}$$

2. 矩阵 LU 分解.

Doolittle 分解: L 斜线处均为 1.

Crout 分解: U 斜线处均为 1.

先以后L

$$L_{32} = \frac{a_{32} - l_{31}u_{12}}{u_{22}} \quad [\text{原值减去}(L\text{同行前面求过的值乘对应}U\text{阵同列前面求过的值), 最后除以}U\text{阵主元}]$$

$$u_{33} = a_{33} - l_{31}u_{13} - l_{32}u_{23} \quad l_{43} = \frac{a_{43} - l_{41}u_{13} - l_{42}u_{23}}{u_{33}}$$

$$\text{при } k=2, \dots, n \quad u_{kj} = a_{kj} - \sum_{s=1}^{k-1} l_{ks} \cdot u_{sj} \quad (j=k, \dots, n).$$

$$l_{ik} = (a_{ik} - \sum_{s=1}^{k-1} l_{is} \cdot u_{sk}) / u_{kk} \quad (i=k+1, \dots, n, k \neq n)$$

第三元的三角分解：每次更新L和U时候，先预计算一次L列的值，哪个大就把它放在第一行

同时可以得到置换矩阵 $P$ 。第 $k$ 次计算用到原第 $t$ 行,那么 $P$ 的 $(k,t)$ 就为1。

### 1. Cholesky 分解、一平方根法

正定: 对任意非零向量  $x$ ,  $x^T A x > 0$ .

存在下三角矩阵  $L$  使得  $A = LL^T$

$$\begin{cases} l_{jj} = (a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2)^{-\frac{1}{2}} \\ l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}) / l_{jj} \quad (i=j+1, \dots, n) \end{cases}$$

改用 (不开方):  $A = LDL^T$

$$A = LDL^T \quad \begin{cases} t_{ij} = a_{ij} - \sum_{k=1}^{j-1} t_{ik} l_{jk}, & j=1, 2, \dots, i-1 \\ l_{ij} = \frac{t_{ji}}{d_j}, & j=1, 2, \dots, i-1 \\ d_{ii} = a_{ii} - \sum_{k=1}^{i-1} t_{ik} l_{ik} \end{cases}$$

2. 严格对角占优.

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \text{ 对 } i=1, 2, \dots, n \text{ 都成立时, } A \text{ 严格对角占优.}$$

可以进行高斯消元而不需要行交换.

三对角矩阵可以用追赶法求解：

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \ddots & \ddots & \ddots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{bmatrix}$$

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$b = \begin{bmatrix} d_1 \\ \vdots \\ d_n \end{bmatrix}$$

于是:  $\begin{cases} a_i \neq 0, c_i \neq 0. \\ |b_i| > |c_i|, |b_i| \geq |a_i| + |c_i|, |b_i| > |a_i| \end{cases}$

分解后: L、U.

$$\begin{cases} d_i = c_i \\ u_i = b_i \\ L_i = a_i / u_{i-1} \\ u_i = b_i - L_i c_{i-1} \end{cases}$$

l u d



## 五. 矩阵迭代解法 Ch7

1. 向量和矩阵范数, (以向量为自变量, 非负实数为函数值的函数)

$$\text{向量: } \|X\|_1 = \sum_{i=1}^n |x_i| \quad \|X\|_2 = \sqrt{\sum_{i=1}^n x_i^2} \quad \|X\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

$$\text{矩阵: } \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \quad \|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad \|A\|_2 = \sqrt{\max \lambda(A^T A)} \quad \|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

列范数: 每列之和的最大值

行范数

谱范数:  $A^T A$  的最大特征值

F 范数.

范数的条件: (i)  $\|A\| \geq 0$  (ii)  $\|A\| = 0$  当且仅当  $A$  为零矩阵. (iii)  $\|A\| = \|A\|$  (Euclidean 范数).

$$(iv) \|A+B\| \leq \|A\| + \|B\| \quad (v) \|AB\| \leq \|A\| \|B\|$$

2. 特征值与特征向量:  $(A - \lambda E)x = 0$

3. Jacobi 迭代法:

$$X^{(k+1)} = B X^{(k)} + d$$

收敛性判断: 严格对角占优 (或)  $B$  的任意一种矩阵范数小于等于 1 (充分条件)

$B$  的谱半径小于 1 (充要条件)

$$B = -D^{-1}(L+U) \quad d = D^{-1}b$$

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad (\text{各个位置除以本行的对角元素})$$

4. Gauss-Seidel 迭代法, [上式子的结果代入下一个].

$$X^{(k+1)} = G X^{(k)} + d$$

等效简单迭代法.

$$G = -(D+L)^{-1}U \quad d = (D+L)^{-1}b$$

Jacobi 中式子为:

$$\begin{aligned} x_1^{(k+1)} &= 0x_1^{(k)} + (-\frac{a_{12}}{a_{11}})x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} - \dots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}} \\ x_n^{(k+1)} &= -\frac{a_{n1}}{a_{nn}}x_1^{(k)} - \frac{a_{n2}}{a_{nn}}x_2^{(k)} - \dots - 0x_n^{(k)} + \frac{b_n}{a_{nn}} \end{aligned}$$

Gauss-Seidel 为:

$$\begin{aligned} x_1^{(k+1)} &= 0x_1^{(k)} - \frac{a_{12}}{a_{11}}x_2^{(k)} - \dots - \frac{a_{1n}}{a_{11}}x_n^{(k)} + \frac{b_1}{a_{11}} \\ x_2^{(k+1)} &= -\frac{a_{21}}{a_{22}}x_1^{(k+1)} - 0x_2^{(k)} - \dots - \frac{a_{2n}}{a_{22}}x_n^{(k)} + \frac{b_2}{a_{22}} \\ x_n^{(k+1)} &= -\frac{a_{n1}}{a_{nn}}x_1^{(k+1)} - \frac{a_{n2}}{a_{nn}}x_2^{(k+1)} - \dots - \frac{a_{nn}}{a_{nn}}x_n^{(k)} + \frac{b_n}{a_{nn}} \end{aligned}$$

收敛性判断: 严格对角占优或对称正定或  $B$  的任一范数小于等于 1 (充分).

$B$  的谱半径小于 1 (充要).

注: 若无法直接通过原系数矩阵判断收敛性, 就要求迭代矩阵, 否则可直接计算.

例: 取  $x_0 = (1, 0, 0)^T$ , 用 GS 迭代求解  $\begin{cases} 9x_1 - 2x_2 + x_3 = 6 \\ -x_1 + 8x_2 - x_3 = 8 \\ -x_1 + x_2 + 8x_3 = -8 \end{cases}$ , 要求  $\|X^{(k+1)} - X^{(k)}\|_\infty \leq 10^{-3}$ .

解:  $A$  严格对角占优, 则 GS 迭代法收敛.

列表:  $k \quad x_1^{(k)} \quad x_2^{(k)} \quad x_3^{(k)} \quad \|X^{(k+1)} - X^{(k)}\|_\infty$

$$\text{迭代格式: } \begin{cases} x_1^{(k+1)} = \frac{2}{9}x_2^{(k)} - \frac{1}{9}x_3^{(k)} + \frac{2}{3} \\ x_2^{(k+1)} = \frac{1}{8}x_1^{(k+1)} + \frac{1}{8}x_3^{(k)} + 1 \\ x_3^{(k+1)} = \frac{1}{8}x_1^{(k+1)} - \frac{1}{8}x_2^{(k+1)} - 1 \end{cases}$$

$$X^{(k+1)} = H X^{(k)} + g \quad \|H\| \text{ 越小, 收敛越快}$$

$$\text{误差估计式: } \|X^{(k)} - X^*\| \leq \frac{\|H\|}{1 - \|H\|} \|X^{(k)} - X^{(k-1)}\|$$

$$\|X^{(k)} - X^*\| \leq \frac{\|H\|^k}{1 - \|H\|} \|X^{(1)} - X^{(0)}\|$$

$\therefore P(H) \leq \|H\| \quad \therefore P(H) < 1$  为收敛的充要条件.

5. SOR 迭代.

收敛必要条件:  $0 < \omega < 2$ .

$$X_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega(\text{Jacobi 迭代})$$

$$\begin{cases} T = (D - \omega L)^{-1} [(1-\omega)D + \omega U] \\ d = \omega(D - \omega L)^{-1}b \end{cases}$$

$$\text{Jacobi: } \begin{aligned} \hat{x}_1^{(k+1)} &= 4 - 2x_2^{(k)} - x_3^{(k)} \\ \hat{x}_2^{(k+1)} &= \frac{1}{5}[7 - 2x_1^{(k)} - 3x_3^{(k)}] \\ \hat{x}_3^{(k+1)} &= \frac{1}{3}[-1 + 2x_1^{(k)} + 2x_2^{(k)}] \end{aligned}$$

$$\text{SOR: } \begin{aligned} x_1^{(k+1)} &= (1-\omega)x_1^{(k)} + \omega\hat{x}_1^{(k+1)} \\ x_2^{(k+1)} &= (1-\omega)x_2^{(k)} + \omega\hat{x}_2^{(k+1)} \\ x_3^{(k+1)} &= (1-\omega)x_3^{(k)} + \omega\hat{x}_3^{(k+1)} \end{aligned}$$

$$\text{例: } \begin{bmatrix} 1 & 2 & 1 \\ 2 & 5 & 3 \\ -2 & -2 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \\ -1 \end{bmatrix}$$

## 六. 条件数与特征向量 Ch 7 Ch 9

1. 对于  $Ax=b$ . 若  $A, b$  的微小变化使  $x$  的解发生巨大变化, 则为病态方程组.

① 若  $b$  有扰动误差  $\delta b$ ,  $A$  无扰动.

$$\text{则 } \frac{\| \delta x \|}{\| x \|} \leq \| A^{-1} \| \| A \| \frac{\| \delta b \|}{\| b \|} \quad \text{引起的相对误差} \leq b \text{ 的相对误差的 } \| A^{-1} \| \cdot \| A \| \text{ 倍.}$$

② 若  $A$  有扰动  $\delta A$ ,  $b$  无扰动.

$$\text{则 } \frac{\| \delta x \|}{\| x \|} \leq \| A^{-1} \| \| A \| \frac{\| \delta A \|}{\| A \|} \quad \text{引起的相对误差} \leq A \text{ 的相对误差的 } \| A^{-1} \| \| A \| \text{ 倍.}$$

2. 条件数  $\text{cond}(A) = \| A \| \| A^{-1} \|$  表述解对原始数据的敏感度.

$$\text{cond}(A)_{\infty} = \| A \|_{\infty} \| A^{-1} \|_{\infty}$$

$$\text{cond}(A)_2 = \| A \|_2 \| A^{-1} \|_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}$$

性质: ① 对任何非奇异矩阵  $A$ , 都有  $\text{cond}(A) \geq 1$

$$\text{cond}(A) = \| A \| \| A^{-1} \| \geq \| A \cdot A^{-1} \| = 1.$$

$$\text{② } \text{cond}(QA) = \text{cond}(A).$$

$$\text{③ 若 } A \text{ 正交矩阵, } \text{cond}(A)_2 = 1$$

$$\text{若 } A \text{ 非奇异, } R \text{ 正交, } \text{cond}(RA)_2 = \text{cond}(AR)_2 = \text{cond}(A)_2$$

若  $\text{cond}(A) \gg 1$  则为病态.

一般判断矩阵病态的方法:

①  $A$  在三角化时出现小主元

②  $A$  的行列式绝对值很小.

③ 元素之间数量级相差很大, 无规则.

2. 幂法求最大特征值和特征向量.

$$A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \quad v_0^{(0)} = (0, -0.5, 1)^T, \text{ 误差} \leq 10^{-3}.$$

[随机取, 一般  $(1, 0, 0)$ ]

$$\text{解: } v = A \cdot u \quad m = \max(v) \quad u = \frac{v}{m}$$

$$m^{(0)} = 1 \quad u_0^{(0)} = (0, -0.5, 1)^T \quad v^{(1)} = A \cdot u_0^{(0)}$$

... 一直迭代直到  $m$  上下误差  $\leq 10^{-3}$  则为特征值, 此时  $m$  对应的  $u = \frac{v}{m}$  为特征向量

## 七. 插值 Ch 3

1. Lagrange 插值.

给出  $n+1$  组数据, 使用唯一确定的不超过  $n$  次的多项式来近似 - 多项式插值.

令  $g(x) = y_0 l_0(x) + y_1 l_1(x) + \dots + y_n l_n(x)$ , 其中  $l_i(x)$  是关于  $x$  的多项式. [存在且唯一]

$$l_i(x) = \begin{cases} 1, & j=i \\ 0, & j \neq i \end{cases} \quad \therefore l_i(x) = \frac{(x-x_0)(x-x_1)\dots(x-x_{i-1})(x-x_{i+1})\dots(x-x_n)}{(x_i-x_0)(x_i-x_1)\dots(x_i-x_{i-1})(x_i-x_{i+1})\dots(x_i-x_n)}$$

$$\text{插值余项: } R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = (x-x_0)\dots(x-x_n)$$

2. Newton 插值.

$$p(x) = c_0 + c_1(x-x_0) + c_2(x-x_0)(x-x_1) + \dots + c_n(x-x_0)(x-x_1)\dots(x-x_{n-1})$$

差商:  $x \quad f(x) \quad \text{一阶差商} \quad \text{二阶差商}$

$$x_0 \quad f(x_0) \quad \text{①}$$

$$x_1 \quad f(x_1) \quad [f(x_0, x_1)]$$

$$x_2 \quad f(x_2) \quad [f(x_1, x_2)] \quad [f(x_0, x_1, x_2)] = \frac{f(x_1, x_2) - f(x_0, x_1)}{x_2 - x_0}$$

$$p(x) = f(x_0) + [f(x_0, x_1)](x-x_0) + [f(x_0, x_1, x_2)](x-x_0)(x-x_1) + \dots + [f(x_0, \dots, x_n)](x-x_0)\dots(x-x_{n-1})$$

① 节点顺序不影响大小,  $[f(x_0, x_1, \dots, x_n)] = [f(x_n, x_0, \dots, x_{n-1})]$

$$\text{② } [f(x_0, x_1, \dots, x_n)] = \frac{f^{(n)}(\xi)}{n!}$$

例:  $f(0)=1, f(1)=3, f(2)=11, f'(1)=4$  求  $P_3(x), R_n(x)$

$$\text{解: } P_2(x) = 3x^2 - x + 1.$$

$$\text{则 } P_3(x) - P_2(x) = kx(x-1)(x-2).$$

$$P_3'(1) = 4 \quad \therefore k=1 \quad P_3(x) = x^3 + x + 1.$$

$$R_n(x) = \frac{f^{(n)}(\xi)}{n!} x(x-1)^2(x-2).$$

法2: 带重节点的差商表:

$x$	$f(x)$	一阶	二阶	三阶
0	1			
1	3	2		
1	3	4	2	
2	11	8	4	1



### 3. Hermit 插值 - 拉格朗日的推广

对于  $x_0, x_1$  形式的:  $H(x) = f(x_0) \cdot \alpha_0(x) + f(x_1) \cdot \alpha_1(x) + f'(x_0) \cdot \beta_0(x) + f'(x_1) \cdot \beta_1(x)$

其中  $\alpha_0(x) = (1 + 2 \frac{x-x_0}{x_1-x_0}) (\frac{x-x_1}{x_0-x_1})^2$   $\alpha_1(x) = (1 + 2 \frac{x-x_1}{x_0-x_1}) (\frac{x-x_0}{x_1-x_0})^2$

$\beta_0(x) = (x-x_0) (\frac{x-x_1}{x_0-x_1})^2$   $\beta_1(x) = (x-x_1) (\frac{x-x_0}{x_1-x_0})^2$  余项  $R_3(x) = \frac{f^{(4)}(\xi)}{4!} (x-x_0)^2 (x-x_1)^2$

重节点, 差商表解决:

已知  $n$  个  $x$ ,  $n$  个值的函数值, ...,  $m$  阶导数值, 与差商表时就把一个  $x$  重复写  $m+1$  遍.

一阶导:  $x$   $f(x)$   $f'(x)$  最后构造牛顿插值多项式

$x_0$	$f(x_0)$	$f'(x_0)$
$x_0$	$f(x_0)$	$f'(x_0)$
$x_1$	$f(x_1)$	
$x_1$	$f(x_1)$	$f'(x_1)$
$x_2$	$f(x_2)$	
$x_2$	$f(x_2)$	$f'(x_2)$

### 4. 三次样条插值

思想:  $[a, b]$  内划分  $n$  个区间, 每个区间做三次样条插值拟合.

边界条件: ①  $S''(x_0) = y_0''$   $S''(x_n) = y_n''$  当  $y_0'' = y_n'' = 0$  为自然样条.

②  $S'(x_0) = y_0'$   $S'(x_n) = y_n'$

③  $S'(x_0) = S'(x_n)$   $S''(x_0) = S''(x_n)$  适用于周期函数.

若  $B$  样条为基底的三次样条插值函数:

$S(x) = \sum_{j=0}^{n-2} C_j \Omega_j(\frac{x-x_{j+1}}{h})$ ,  $a \leq x \leq b$ ,  $h = \frac{b-a}{n}$  其中  $\Omega_3(x) = \begin{cases} 0, & |x| \geq 2 \\ \frac{1}{6}|x|^3 - x^2 + \frac{3}{2}, & |x| \leq 1 \\ -\frac{1}{6}|x|^3 + x^2 - 2|x| + \frac{11}{6}, & 1 < |x| < 2 \end{cases}$

① 第一种边界条件:  $\begin{bmatrix} 4 & 1 & & \\ 1 & 4 & & \\ & \ddots & \ddots & \\ & & 1 & 4 & \\ & & & 1 & 4 \end{bmatrix} \begin{bmatrix} C_2 \\ \vdots \\ C_n \end{bmatrix} = \begin{bmatrix} 6y_1 - y_0 + \frac{h^2}{6}y_0'' \\ 6y_2 \\ \vdots \\ 6y_{n-2} \end{bmatrix}$

$C_0 = 2y_1 - y_0 + \frac{h^2}{6}y_0''$   
 $C_1 = y_2 - \frac{h^2}{6}y_0''$   
 $C_{n-1} = y_{n-1} - \frac{h^2}{6}y_n''$   
 $C_{n-2} = 2y_{n-1} - y_n + \frac{h^2}{6}y_n''$

② 第二种边界条件:  $\begin{bmatrix} 4 & 2 & & \\ 1 & 4 & & \\ & \ddots & \ddots & \\ & & 1 & 4 & \\ & & & 1 & 4 \end{bmatrix} \begin{bmatrix} C_1 \\ \vdots \\ C_{n-1} \end{bmatrix} = \begin{bmatrix} 6y_0 + 2hy_0' \\ 6y_1 \\ \vdots \\ 6y_{n-1} - 2hy_n' \end{bmatrix}$

$C_0 = C_2 - 2hy_0'$   
 $C_{n-2} = C_{n-1} + 2hy_n'$

③ 第三种边界条件:  $\begin{bmatrix} 4 & 1 & & & 1 \\ 1 & 4 & & & \\ & \ddots & \ddots & & \\ & & 1 & 4 & \\ & & & 1 & 4 \end{bmatrix} \begin{bmatrix} C_2 \\ \vdots \\ C_{n-1} \end{bmatrix} = \begin{bmatrix} 6y_1 \\ 6y_2 \\ \vdots \\ 6y_{n-1} \end{bmatrix}$

$C_{n-2} = C_2$   
 $C_1 = C_{n-1}$   
 $C_0 = C_n$

三弯矩法:

$S(x) = \frac{M_{i-1}}{6h_i} (x_i - x)^3 + \frac{M_i}{6h_i} (x - x_{i-1})^3 + (\frac{y_{i-1}}{h_i} - \frac{M_{i-1}}{6}h_i)(x_i - x) + (\frac{y_i}{h_i} - \frac{M_i}{6}h_i)(x - x_{i-1})$   $x_{i-1} \leq x \leq x_i$

$y_i M_{i-1} + 2M_i + y_i M_{i+1} = \beta_i$  (三弯矩方程)  $\Rightarrow \alpha = \frac{h_{i+1}}{h_i + h_{i+1}}$   $\gamma_i = 1 - \alpha$   $\beta_i = \frac{6}{h_i + h_{i+1}} (\frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i})$

① 第一种边界条件:  $\alpha_0 = 0$   $\beta_0 = 2y_0''$   $\gamma_n = 0$   $\beta_n = 2y_n''$

② 第二种边界条件:  $\alpha_0 = 1$   $\gamma_n = 1$   $\beta_0 = \frac{6}{h_1} (\frac{y_1 - y_0}{h_1} - y_0')$

$\beta_n = \frac{6}{h_n} (y_n' - \frac{y_n - y_{n-1}}{h_n})$  代入①中方程求解.

③ 第三种边界条件:  $M_0 = M_n$   $\alpha_n = \frac{h_n}{h_n + h_{n+1}}$   $\gamma_n = 1 - \alpha_n$   $\beta_n = \frac{6}{h_n + h_{n+1}} (\frac{y_{n+1} - y_n}{h_{n+1}} - \frac{y_n - y_{n-1}}{h_n})$

$\begin{bmatrix} 2 & \alpha_0 & & & \\ \gamma_1 & 2 & \alpha_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \gamma_{n-1} & 2 & \alpha_{n-1} \\ & & & \gamma_n & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ \vdots \\ M_n \end{bmatrix} = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_n \end{bmatrix}$

$\begin{bmatrix} 2 & \alpha_1 & & & \\ \gamma_2 & 2 & \alpha_2 & & \\ & \ddots & \ddots & \ddots & \\ & & \gamma_{n-1} & 2 & \alpha_{n-1} \\ \alpha_n & & & \gamma_n & 1 \end{bmatrix} \begin{bmatrix} M_1 \\ \vdots \\ M_n \end{bmatrix} = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_n \end{bmatrix}$

# 八. 函数逼近与曲线拟合

逼近: 连续函数逼近连续函数  
拟合: 连续函数拟合离散数据

ch 8

## 1. 最小二乘法拟合

权函数: 每个点加入权重,  $w(x)$

$$\sum_{k=1}^n w_k (f(x_k) - \varphi(x_k))^2 = \min$$

$$\text{span}\{1, x, x^2\} \quad (\varphi_0, \varphi_0) = \sum_{i=1}^n \varphi_0 \times \varphi_0 = n$$

$$(\varphi_0, \varphi_1) = \sum_{i=1}^n x_i$$

例: 拟合五个数据点, 变成二次函数:

$$\begin{cases} a_0 + a_1 x_1 + a_2 x_1^2 = y_1 \\ a_0 + a_1 x_2 + a_2 x_2^2 = y_2 \\ \vdots \\ a_0 + a_1 x_5 + a_2 x_5^2 = y_5 \end{cases}$$

$$\Rightarrow \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_5 & x_5^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_5 \end{bmatrix} \quad A \cdot x = b$$

$$\text{法方程: } \begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & (\varphi_0, \varphi_2) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) \\ (\varphi_2, \varphi_0) & (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ (f, \varphi_2) \end{bmatrix}$$

$$\text{例: } x \quad -1 \quad 0 \quad 1 \quad 2 \quad 3 \quad 4$$

$$f(x) \quad 0.8 \quad 0.7 \quad 0.6 \quad 0.4 \quad 0.1 \quad -0.2$$

$$\varphi_0 = 1 \quad \varphi_1 = x \quad \varphi_2 = x^2$$

$$(\varphi_0, \varphi_0) = 6 \quad (\varphi_0, \varphi_1) = \sum x_i = 9 \dots$$

$$(f, \varphi_0) = \sum f(x) \dots$$

但  $(A^T A) x = A^T b$  可以近似拟合上述解, 求出  $A^T A, A^T b$  即可解方程组

## 2. 最佳平方逼近

逼近:  $f(x) = x^2$  在  $[1, 1]$  上关于权函数  $\rho(x) = 1$  的二次最佳平方逼近

$\varphi(x) = a + bx + cx^2$  则  $\varphi_0(x) = 1, \varphi_1(x) = x, \varphi_2(x) = x^2$  - 基函数

$$M = \text{span}\{1, x, x^2\} \quad \text{法方程组: } \begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & (\varphi_0, \varphi_2) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & (\varphi_1, \varphi_2) \\ (\varphi_2, \varphi_0) & (\varphi_2, \varphi_1) & (\varphi_2, \varphi_2) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ (f, \varphi_2) \end{bmatrix}$$

交叉项

$$\text{用内积公式: } (h, g) = \int_1^1 h(x) g(x) dx$$

$$\text{得 } \begin{bmatrix} 2 & 0 & \frac{2}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{2}{3} & 0 & \frac{2}{5} \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} \frac{2}{5} \\ 0 \\ \frac{2}{7} \end{bmatrix} \quad \text{解得 } \begin{cases} a = -\frac{3}{35} \\ b = 0 \\ c = \frac{4}{7} \end{cases}$$

## 3. 正交多项式

$$(\varphi_i(x), \varphi_k(x)) = \begin{cases} 0, & i \neq k \\ A_k, & i = k \end{cases} \quad A_k = 1 \text{ 称为标准正交函数族}$$

有勒让德多项式和切比雪夫多项式

## 4. 勒让德多项式逼近 Legendre 适用条件 $[-1, 1]$

$$\begin{cases} P_0(x) = 1 \\ P_1(x) = x \\ P_2(x) = \frac{1}{2}(3x^2 - 1) \\ P_3(x) = \frac{1}{2}(5x^3 - 3x) \end{cases}$$

$$P_{n+1}(x) = \frac{2n+1}{n+1} x P_n(x) - \frac{n}{n+1} P_{n-1}(x)$$

$$[P_i, P_j] \text{ 代替 } [\varphi_i, \varphi_j] \quad (P_i, P_j) = \begin{cases} 0, & i \neq j \\ \frac{1}{2j+1}, & i = j \end{cases}$$

例:  $f(x) = x^4, [-1, 1]$ , 二次逼近

$$\begin{bmatrix} 2 & 0 & \frac{2}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{2}{3} & 0 & \frac{2}{5} \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} (P_0, f) \\ (P_1, f) \\ (P_2, f) \end{bmatrix} \quad \text{解得 } a, b, c$$

$$(P_0, f) = \int_{-1}^1 P_0 \cdot f(x) dx$$

$$S(t) = a P_0 + b P_1 + c P_2$$

对于  $f(x), x \in [a, b]$ , 可以将  $x = \frac{a+b}{2} + \frac{b-a}{2}t$  用  $t$  代替,  $t \in [-1, 1]$ ,  $f(t) = \dots$  (如  $(-\frac{1}{2} + \frac{1}{2}t)^4$ )

最后再换回来

## 5. 切比雪夫多项式逼近 Chebyshev $P(x) = \frac{1}{\sqrt{1-x^2}}$ 适用条件 $[-1, 1]$

$$\begin{cases} (T_0, T_0) = \pi \\ (T_1, T_1) = \frac{\pi}{2} \\ (T_2, T_2) = \frac{\pi}{2} \end{cases} \quad \begin{cases} T_0 = 1 \\ T_1 = x \\ T_2 = 2x^2 - 1 \\ T_3 = 4x^3 - 3x \end{cases} \quad \begin{cases} (f, T_0) = \int_{-1}^1 f(x) \cdot T_0 \cdot \frac{1}{\sqrt{1-x^2}} dx \\ T_n(x) = \cos(n \arccos x) \\ T_{n+1}(x) = 2x T_n(x) - T_{n-1}(x) \end{cases}$$

## 6. 最佳一致逼近

## 7. 最小二乘法拟合 - 正交多项式版本 $P_{n+1}(x) = (x - a_n) P_n(x) - b_n P_{n-1}(x)$

$$\text{例: } x \quad -2 \quad -1 \quad 0 \quad 1 \quad 2$$

$$f(x) \quad -0.1 \quad 0.1 \quad 0.4 \quad 0.9 \quad 1.6$$

$$\begin{aligned} \varphi_0 = 1 \quad (\varphi_0, \varphi_0) = 5 \quad \therefore a_1 = \frac{(x \varphi_0, \varphi_0)}{(\varphi_0, \varphi_0)} = 0 \quad (\varphi_1, \varphi_1) = 2 \quad a_2 = 0 \\ (x \varphi_0, \varphi_0) = \sum x = 0 \quad \varphi_1(x) = x \quad (x \varphi_1, \varphi_1) = 0 \quad b_1 = 2 \end{aligned}$$

$$a_n = \frac{(x P_n, P_n)}{(P_n, P_n)} \quad b_n = \frac{(P_n, P_{n-1})}{(P_{n-1}, P_{n-1})} \quad \begin{cases} P_0(x) = 1 \\ P_1(x) = 0 \end{cases}$$

$$\begin{aligned} \varphi(y, \varphi_0) &= \sum y \\ (y, \varphi_1) &= \sum x y \\ (y, \varphi_2) &= \sum (x^2 - 2) y \end{aligned} \quad \begin{cases} a_0^* = \frac{(y, \varphi_0)}{(\varphi_0, \varphi_0)} = 0.58 \\ \vdots \end{cases}$$



## 九. 数值微分与积分. Ch4

### 1. 数值微分: 近似求导数.

- 阶两点公式:  $f'(x_0) \approx f'(x_1) \approx \frac{f(x_1) - f(x_0)}{h}$

- 阶三点公式:  $f'(x_0) \approx \frac{-3f(x_0) + 4f(x_1) - f(x_2)}{2h}$   $f'(x_1) \approx \frac{-f(x_0) + f(x_2)}{2h}$   $f'(x_2) \approx \frac{f(x_0) - 4f(x_1) + 3f(x_2)}{2h}$

拉格朗日插值公式可推导!

主:  $f'(x_0) = \frac{1}{12h} [f(x_0-2h) - 8f(x_0-h) + 8f(x_0+h) - f(x_0+2h)] + \frac{h^4}{30} f^{(5)}(\xi)$

$f'(x_0) = \frac{1}{12h} [-25f(x_0) + 48f(x_0+h) - 36f(x_0+2h) + 16f(x_0+3h) - 3f(x_0+4h)] + \frac{h^4}{5} f^{(5)}(\xi)$

### 2. 数值积分基础——Newton-Cotes公式

梯形法则:  $\int_a^b f(x) dx \approx \frac{h}{2} [f(x_0) + f(x_1)] - \frac{h^3}{12} f''(\xi)$

Cotes公式:  $C = \frac{b-a}{90} [7, 32, 12, 32, 7]$

Simpson 法则:  $\int_{x_0}^{x_2} f(x) dx \approx \frac{h}{3} [f(x_0) + 4f(x_1) + f(x_2)] - \frac{h^5}{90} f^{(4)}(\xi)$

代数精度: 对不超过  $m$  的次数的多项式都成立,  $(m+1)$  不成立.

例: 构造下列公式使精确度最高:

① 拥有奇数  $n+1$  个节点的求积公式, 代数精度至少为  $n+1$

$\int_0^1 f(x) dx \approx A_0 f(0) + A_1 f(\frac{1}{3})$

② 具有  $n+1$  个节点的求积公式 精度最高为  $2n+1$ .

至少有一次精度, 将  $f(x)=1$ ,  $f(x)=x$  代入.

$\begin{cases} \int_0^1 1 dx = A_0 + A_1 \\ \int_0^1 x dx = 0A_0 + \frac{1}{3}A_1 \end{cases} \Rightarrow \begin{cases} A_0 = \frac{1}{4} \\ A_1 = \frac{3}{4} \end{cases}$

验证  $f(x)=x^2$  成立  $\therefore$  精度为 2.

$f(x)=x^3$  不成立

$h = \frac{b-a}{n}$ ,  $x_k = a + kh$ ,  $\int_a^b f(x) dx \approx (b-a) \sum_{k=0}^n C_k^{(n)} f_k$  为 N-K 公式.

$n=8$  开始  $C_k$  会出现负数  $\Rightarrow$  不稳定

### 3. 复化求积公式.

分段插值.

复化中点:  $M_n(f) = h f(x_{i+\frac{1}{2}}) + \frac{h^3(b-a)}{24} f''(\xi)$

复化梯形:  $T_n(f) = \frac{h}{2} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)] - \frac{(b-a)h^2}{12} f''(\xi)$

复化 Simpson:  $S_n(f) = \frac{h}{3} [f(a) + 2 \sum_{j=1}^{\frac{n}{2}-1} f(x_{2j}) + 4 \sum_{j=1}^{\frac{n}{2}-1} f(x_{2j-1}) + f(b)] - \frac{(b-a)h^4}{180} f^{(4)}(\xi)$

### 4. Romberg 算法.

① 用递推的梯形公式迭代.  $T_0^{(k)}$  上标为第  $k$  次迭代, 下标为精度

② 首次迭代完用 Romberg 公式修正:  $T_m^{(k)} = \frac{4^m}{4^m - 1} T_{m-1}^{(k+1)} - \frac{1}{4^m - 1} T_{m-1}^{(k)}$

③ 完成修正得到  $T_k^{(k)}$ , 误差为  $|T_k^{(k)} - T_{k-1}^{(k)}|$ .

例:  $f(x) = x^{\frac{1}{2}}$  在  $[0, 1]$  积分.

$x$	$f(x)$
0	0
1	1
0.5	0.3535

$T_0^{(0)} = \frac{1}{2} (1-0)$

$T_0^{(1)} = \frac{1}{2} T_0^{(0)} + \frac{1}{2} f(0.5) = 0.4267$

$T_1^{(0)} = \frac{4}{3} T_0^{(0)} - \frac{1}{3} T_0^{(1)} = 0.402$

$|T_1^{(0)} - T_0^{(1)}| = 0.09763$

$T_0^{(0)} \rightarrow T_1^{(0)}$

- 1 个节点: 0  
2 个:  $\pm \frac{\sqrt{3}}{2}$   
3 个: 0,  $\pm \sqrt{0.6}$

Richardson 外推加速:  $T_m(h) = I + \delta_1 h^{2(m+1)} + \delta_2 h^{2(m+2)} + \dots$

### 5. 自适应求积, adaptive method.

$S(a, \frac{a+b}{2}) = \frac{h}{6} [f(a) + 4f(a+\frac{1}{2}) + f(a+h)]$

$S(\frac{a+b}{2}, b) = \frac{h}{6} [f(a+h) + 4f(a+\frac{3}{2}h) + f(b)]$

将 Simpson 重写为  $S(a, \frac{a+b}{2}) + S(\frac{a+b}{2}, b) - \frac{h^5}{72} f^{(4)}(\xi)$

6. 高斯求积——非等距点  $\int_{-1}^1 f(x) dx \approx \sum_{i=1}^n G_i f(x_i)$

代数精度为  $2n+1$ . 转换为  $[-1, 1]$  区间, 用勒

让使求零点, 根的位置即为取点位置

例:  $n=2$ , 求  $\int_0^1 x^2 \ln x dx$

$a=1, b=1.5 \therefore x = \frac{1}{6} + \frac{5}{6}t$ . 查得  $n=2$  时  $\pm \frac{\sqrt{3}}{2}$

原式  $= \frac{1}{4} \int_{-1}^1 (\frac{1}{6} + \frac{5}{6}t)^2 \ln(\frac{1}{6} + \frac{5}{6}t) dt$

$= \frac{1}{4} (1.05^2 \ln 1.05 + 1.39^2 \ln 1.39)$

$= 0.192$

1. 微分方程数值解法: 显示法与隐式法, Runge-Kutta, 稳定性. Ch 5

1. 常微分方程:

$$\begin{cases} \frac{dy}{dx} = f(x, y) & \text{-- 方程} \\ y(x_0) = y_0 & \text{-- 初值} \end{cases}$$

2. 欧拉法:  $y_{n+1} = y_n + h f(x_n, y_n)$ . 一显式 Euler 公式.

(h 为步长).

$$y_{n+1} = y_n + h f(x_{n+1}, y_{n+1}) \text{ -- 隐式 Euler 公式.}$$

$$y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})] \text{ -- 梯形 Euler 公式.}$$

具体解法:

$$\begin{cases} \hat{y}_{n+1} = y_n + h f(x_n, y_n) & \text{-- 预估算式} \\ y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, \hat{y}_{n+1})] & \text{-- 校正算式} \end{cases}$$

3. 精度的阶数:

$$\text{局部截断误差: } T_{n+1} = y(x_{n+1}) - y_{n+1} = \frac{h^2}{2} y''(x_n) + O(h^3) \Rightarrow T_{n+1} = O(h^2) \text{ 显式 Euler 误差.}$$

泰勒展开

Euler 公式

同理  $T_{n+1} = O(h^2)$  隐式 Euler 误差.

$$= -\frac{h^2}{2} y''(x_n) + O(h^3)$$

若  $T_{n+1} = O(h^{p+1})$  则该算法有  $p$  阶精度.

Euler 显式, 隐式 -- 一阶

梯形 Euler. -- 二阶

Taylor (展开到  $k$  次) --  $k$  阶.

4. 龙格-库塔法 (Runge-Kutta)

$$\begin{cases} y_{n+1} = y_n + h(b_1 k_1 + b_2 k_2 + \dots + b_s k_s) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + c_2 h, y_n + a_{21} k_1) \\ k_3 = f(x_n + c_3 h, y_n + a_{31} k_1 + a_{32} k_2) \\ \dots \end{cases}$$

一阶: 欧拉法 ( $b_1=1$ )

$$\text{二阶: Euler 改: } \begin{cases} y_{n+1} = y_n + \frac{h}{2} (k_1 + k_2) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + h, y_n + h k_1) \end{cases}$$

$$\text{中点法: } \begin{cases} y_{n+1} = y_n + h k_2 \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2} k_1) \end{cases}$$

$$\text{Heun 方法: } \begin{cases} y_{n+1} = y_n + \frac{h}{4} (k_1 + 3k_2) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{2}{3}h, y_n + \frac{2}{3}h k_1) \end{cases}$$

$$\text{四阶龙格-库塔: } \begin{cases} y_{n+1} = y_n + h(\frac{1}{6}k_1 + \frac{4}{6}k_2 + \frac{2}{6}k_3 + \frac{1}{6}k_4) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{1}{2}h, y_n + \frac{1}{2}h k_1) \\ k_3 = f(x_n + \frac{1}{2}h, y_n + \frac{1}{2}h k_2) \\ k_4 = f(x_n + h, y_n + h k_3) \end{cases}$$

五阶: Runge-Kutta-Fehlberg 方法. 书 (中) 252 页.





# 浙江大学

ZHEJIANG UNIVERSITY

## 5. 变步长的龙格-库塔多步法, P261.

显 Euler 两步法:  $y_{n+1} = y_n + 2hf(x_n, y_n)$

Adams-Bashforth 两步显式:  $y_{n+1} = y_n + \frac{h}{2}(3f(x_n, y_n) - f(x_{n-1}, y_{n-1}))$

A - B 三步显:  $y_{n+1} = y_n + \frac{h}{12}(23f(x_n, y_n) - 16f(x_{n-1}, y_{n-1}) + 5f(x_{n-2}, y_{n-2}))$

A - B 两步隐式:  $y_{n+1} = y_n + \frac{h}{12}(5f(x_{n+1}, y_{n+1}) + 8f(x_n, y_n) - f(x_{n-1}, y_{n-1}))$

## 6. 变步长的龙格-库塔: $\Delta = \frac{h}{15} |y_{n+1}^{\frac{2}{3}} - y_{n+1}^h|$ 直至 $\Delta < \epsilon$ ( $\epsilon$ 为设定)

变步长的多步法: P268. 线性多步公式:  $y_{n+1} = \alpha_0 y_n + \alpha_1 y_{n-1} + \dots + \alpha_k y_{n-k} + h(\beta_0 f_{n+1} + \dots + \beta_k f_{n-k})$

Takay 展开并匹配系数

## 7. 收敛性和稳定性

所有算法均收敛:  $x_n = x_0 + nh$ ,  $h \rightarrow 0$  时  $y_n \rightarrow y(x_n)$ ,  $y(x_n)$  为准确解, 则收敛.

稳定性: 在  $y_n$  上有  $\delta$  的扰动, 以后各节点  $y_m$  产生的偏差均不超过  $\delta$ .

对  $\begin{cases} y' = \lambda y \\ y(x_0) = y_0 \end{cases}$  Euler 在  $|1 + \lambda h| \leq 1$  时稳定 稳定区间  $-2 < \lambda h < 0$

~~梯形~~ 隐式 Euler 对任何  $h$  均稳定.

梯形 Euler  $|1 + \lambda h + \frac{1}{2}(\lambda h)^2| \leq 1$  时稳定 稳定区间  $-2 < \lambda h < 0$ .

RK-4 (龙格库塔4阶)  $|1 + \lambda h + \frac{(h\lambda)^2}{2!} + \frac{(h\lambda)^3}{3!} + \frac{(h\lambda)^4}{4!}| \leq 1$  时稳定, 区间  $-2.78 < \lambda h < 0$ .

(其他 RK 方法均类推.)

解题: 列表法, 以 Euler 梯形为例

$$\begin{cases} y' = x + y & (0 \leq x \leq 0.4) \\ y(0) = 1 \end{cases} \quad \text{代入, 则} \quad \begin{cases} y_{n+1}^{\wedge} = 0.1x_n + 1.1y_n \\ y_{n+1} = 0.05x_n + 0.05x_{n+1} + 1.05y_n + 0.05y_{n+1}^{\wedge} \end{cases}$$

n	$x_n$	$y_n$	$y_{n+1}^{\wedge}$	$y_{n+1}$
0	0	1.0	1.1	1.1
1	0.1	1.1	1.22	1.24205
2	0.2	1.24205		
3	0.3			
4	0.4			